

XGBoost vs. Random Forest: Evaluasi Komparatif untuk Strategi Trading Emas (XAU/USD) dan Bitcoin (BTC/USD) Berbasis Implementasi Praktis

Landasan Teoretis dan Justifikasi Perbandingan Algoritma Pembelajaran Mesin

Perbandingan antara algoritma XGBoost (Extreme Gradient Boosting) dan Random Forest (RF) dalam konteks perdagangan otomatis pada pasangan mata uang logam seperti XAU/USD (emas) dan BTC/USD (Bitcoin) merupakan subjek penelitian yang sangat relevan dan menarik. Justifikasi utama untuk penelitian ini terletak pada tiga domain utama: evolusi metode prediktif di bidang keuangan, karakteristik unik dari aset yang ditargetkan, serta kompleksitas dan nuansa masing-masing algoritma pembelajaran mesin itu sendiri. Secara historis, prediksi pasar keuangan telah bergantung pada model ekonometrika tradisional seperti ARIMA [56]. Namun, kemajuan pesat dalam bidang pembelajaran mesin dan pembelajaran mendalam telah membuka jalan bagi pendekatan yang lebih fleksibel dan kuat dalam menangkap hubungan non-linear yang kompleks dalam data pasar [54, 58]. Studi-studi telah secara sistematis menunjukkan bahwa model-model seperti Random Forest dan Stochastic Gradient Descent sering kali dapat mengungguli model-model tradisional dalam hal profitabilitas dan manajemen risiko [26, 51]. Hal ini menempatkan XGBoost dan RF sebagai kandidat yang sangat menarik untuk dievaluasi lebih lanjut.

Random Forest adalah sebuah ensembler meta-algoritma yang bekerja dengan membangun banyak pohon keputusan selama proses pelatihan dan mengembalikan nilai rata-rata prediksi (untuk regresi) atau hasil voting mayoritas (untuk klasifikasi) dari pohon-pohon individu yang ada di dalamnya [5]. Keunggulan utama RF terletak pada kekokohnya dan ketahanannya terhadap overfitting, bahkan ketika jumlah fitur sangat besar [5]. Proses bootstrap aggregation (bagging) yang menjadi intinya, di mana setiap pohon dilatih pada sampel acak dari data latih, secara signifikan mengurangi varians model tanpa meningkatkan bias secara signifikan. Ini menjadikan RF sebagai pilihan yang andal dan seringkali merupakan titik awal yang baik dalam analisis prediktif keuangan [33].

Di sisi lain, XGBoost adalah implementasi dari algoritma gradient boosting yang dioptimalkan untuk kecepatan dan kinerja tinggi [27]. Berbeda dengan RF yang menggunakan bagging, XGBoost menggunakan teknik boosting. Ia membangun pohon keputusan secara serial, di mana setiap pohon baru berusaha untuk memperbaiki kesalahan yang dibuat oleh kombinasi dari semua pohon sebelumnya. Pendekatan ini sangat kuat dalam menangkap hubungan hierarkis dan interaksi kompleks antar fitur. XGBoost juga

memiliki mekanisme regularisasi internal (L1 dan L2) yang membantu mencegah overfitting lebih efektif daripada banyak model boosting lainnya. Keunggulan XGBoost dalam integrasi berbagai jenis data sumber—seperti data teknikal, fundamental, dan sentimen—telah terbukti dalam beberapa studi, membuatnya sangat menjanjikan untuk aplikasi prediksi harga yang kompleks [3]. Studi yang membandingkan berbagai algoritma untuk prediksi harga Bitcoin bahkan menemukan bahwa XGBoost mampu mencapai rasio Sharpe yang sangat impresif yaitu 1.78 [36].

Meskipun keduanya termasuk dalam keluarga ensemble methods, perbedaan filosofis dan teknis mereka menghasilkan karakteristik performa yang berbeda dalam konteks pasar keuangan. RF cenderung lebih robust dan lebih mudah di-tune karena tidak terlalu rentan terhadap pemilihan hyperparameter yang buruk. Sebaliknya, XGBoost menawarkan potensi akurasi prediksi yang lebih tinggi jika diatur dengan benar, tetapi bisa menjadi "mudah lembek" jika parameter seperti laju belajar atau kedalaman pohon tidak ditentukan dengan hati-hati [49]. Pemilihan antara keduanya bukanlah pilihan biner yang absolut; melainkan sebuah pertimbangan yang bergantung pada karakteristik dataset, tujuan analisis, dan toleransi terhadap kompleksitas model. Beberapa penelitian bahkan menyarankan bahwa model gabungan, seperti Stacking Regressor yang menggabungkan output dari berbagai model termasuk XGBoost dan RF, dapat memberikan kinerja yang lebih superior daripada model tunggal [2].

Justifikasi untuk fokus pada aset XAU/USD dan BTC/USD semakin diperkuat oleh karakteristik pasar yang unik dari kedua instrumen ini. Emas (XAU/USD) secara tradisional berfungsi sebagai aset safe-haven, yang artinya permintaannya cenderung meningkat selama periode ketidakpastian ekonomi, inflasi tinggi, atau gejolak geopolitik [1, 20]. Hubungannya dengan indikator volatilitas seperti VIX dan indeks saham seperti S&P 500 sangat erat, menjadikannya target yang ideal untuk model yang dapat menangkap respons pasar terhadap berita ekonomi [2]. Di sisi lain, Bitcoin (BTC/USD) telah berevolusi dari proyek kripto sampingan menjadi aset alternatif yang signifikan, dengan beberapa analisis menyebutnya sebagai "emas digital" [17, 20]. Namun, perilakunya sangat berbeda dari emas. Bitcoin sangat reaktif terhadap kebijakan moneter bank sentral, khususnya Federal Reserve AS [16, 25]. Kenaikan suku bunga cenderung menekan harga Bitcoin, sementara pemotongan suku bunga sering kali mendorongnya naik. Selain itu, sentimen publik dan aktivitas on-chain juga berperan penting dalam menentukan harga Bitcoin, menjadikannya tantangan prediktif yang berbeda dari emas [6, 28].

Dengan demikian, evaluasi komparatif antara XGBoost dan Random Forest pada kedua aset ini tidak hanya menguji keunggulan teknis model, tetapi juga sejauh mana setiap model dapat menangkap dinamika pasar yang berbeda. Pertanyaan mendasarnya adalah apakah model yang robust dan bersifat agregat seperti Random Forest lebih cocok untuk pasar safe-haven seperti emas, atau apakah model yang sangat adaptif dan presisi tinggi seperti XGBoost lebih unggul dalam menangkap volatilitas dan reaktivitas pasar Bitcoin. Literatur yang ada menunjukkan bahwa tidak ada jawaban tunggal yang benar; hasilnya sangat bergantung pada timeframe, jenis data yang digunakan, dan metrik kinerja yang dipilih [3]. Oleh karena itu, penelitian ini bertujuan untuk memberikan perspektif empiris yang solid

dengan merujuk langsung pada implementasi kode yang telah ada, sehingga menghasilkan wawasan yang tidak hanya teoretis tetapi juga dapat diterapkan secara praktis dalam pengembangan strategi perdagangan berbasis AI.

Konsep dan Mekanisme Strategi Trading Berbasis Implementasi Skrip

Konsep strategi perdagangan yang diusulkan dalam penelitian ini dapat direkonstruksi secara sistematis berdasarkan analisis terhadap struktur dan nomenklatur dari empat skrip Python yang disediakan: `rf_scanning.py`, `xgboost_fix.py`, `xgboost_scanning.py`, dan `rf_fixmodel.py`. Nomenklatur ini secara implisit membedakan antara tahap-tahap krusial dalam siklus pengembangan model machine learning untuk perdagangan, yaitu pelatihan model tetap dan pencarian hiperparameter. Dengan mensintesis informasi dari kode sumber dan kajian literatur terkait, kerangka kerja strategi trading yang diusulkan dapat dirumuskan sebagai berikut:

Langkah pertama adalah **Pengumpulan dan Pra-proses Data**. Strategi ini dirancang untuk menerapkan dua algoritma, Random Forest dan XGBoost, pada dua aset yang berbeda, yaitu XAU/USD (emas) dan BTC/USD (Bitcoin). Pengguna telah menyoroti pentingnya referensi data ekonomi yang relevan. Berdasarkan kajian literatur, data ekonomi ini secara spesifik mencakup Indeks S&P 500, harga minyak mentah, dan Indeks Volatilitas CBOE (VIX) [2, 3]. Data-data ini, yang merefleksikan sentimen pasar dan kondisi makroekonomi global, diintegrasikan dengan data pasar primer seperti harga Buka, Tinggi, Rendah, Tutup (OHLC) dan Volume (OHLCV) untuk setiap aset [22]. Tahap pra-proses ini melibatkan normalisasi data untuk memastikan semua fitur berada dalam skala yang sama, penanganan nilai yang hilang, dan transformasi data agar sesuai untuk model machine learning.

Langkah kedua adalah **Pembuatan Fitur dan Generasi Target**. Setelah data dasar dipersiapkan, langkah selanjutnya adalah rekayasa fitur, sebuah proses krusial untuk mentransformasikan data mentah menjadi informasi yang dapat digunakan oleh model. Rekayasa fitur ini mencakup pembuatan berbagai indikator teknikal yang umum digunakan dalam analisis pasar, seperti Rata-Rata Bergerak Sederhana (SMA), Rata-Rata Bergerak Eksponensial (EMA), Relative Strength Index (RSI), MACD, dan Band Bollinger [2, 21, 39]. Selain itu, fitur-fitur fundamental seperti harga S&P 500, harga minyak, dan nilai VIX juga dimasukkan ke dalam model [2]. Untuk target variabel, strategi ini kemungkinan besar menggunakan pendekatan klasifikasi, di mana model dilatih untuk memprediksi arah pergerakan harga di masa depan (misalnya, 'Naik', 'Turun', atau 'Stabil'). Target ini dapat dihasilkan dengan menggunakan strategi moving average crossover, di mana jika SMA jangka pendek berada di atas SMA jangka panjang, targetnya adalah 'Naik' [22]. Alternatif lain adalah regresi, di mana model memprediksi nilai harga mutlak di waktu mendatang. Tujuan utamanya adalah untuk mengubah masalah prediksi menjadi masalah klasifikasi atau regresi yang dapat diselesaikan oleh model ML.

Langkah ketiga, yang paling intuitif dari namanya, adalah **Pelatihan dan Tuning Model**. Di

sinilah skrip `rf_fixmodel.py` dan `xgboost_fix.py` memainkan peran sentral. File-file ini kemungkinan besar berfungsi sebagai modul untuk melatih dan "menetapkan" model tunggal untuk masing-masing algoritma. Proses ini melibatkan pemecahan data menjadi set pelatihan dan validasi, serta penyesuaian parameter dasar model untuk menghasilkan model awal yang siap digunakan. Namun, kekuatan sebenarnya dari strategi ini terletak pada tahap tuning yang didukung oleh skrip `_scanning.py`. Kata "Scanning" secara kuat mengimplikasikan penggunaan teknik optimasi seperti Grid Search atau Random Search untuk secara sistematis mengeksplorasi ruang parameter yang luas [49]. Skrip `rf_scanning.py` dan `xgboost_scanning.py` akan secara otomatis menguji kombinasi parameter yang berbeda untuk Random Forest dan XGBoost masing-masing, menggunakan metrik validasi silang (misalnya, Mean Absolute Error untuk regresi atau Akurasi untuk klasifikasi) untuk mengevaluasi kinerja setiap kombinasi. Tujuannya adalah untuk menemukan set parameter optimal yang secara signifikan meningkatkan kapabilitas prediksi masing-masing model sebelum digunakan untuk perdagangan.

Langkah keempat adalah **Generasi Sinyal dan Pelaksanaan Perdagangan**. Setelah model Random Forest dan XGBoost yang telah dioptimalkan diperoleh, langkah selanjutnya adalah menggunakannya untuk membuat prediksi pada data pasar waktu-nyata atau data historis yang belum pernah dilihat sebelumnya (data uji luar-contoh) [49]. Prediksi ini berupa probabilitas atau label arah. Misalnya, model XGBoost mungkin memprediksi bahwa ada probabilitas 75% harga BTC/USD akan naik dalam 1 jam ke depan. Probabilitas ini kemudian dikonversi menjadi sinyal perdagangan berdasarkan aturan yang telah ditentukan. Aturan ini bisa sederhana, seperti "beli jika probabilitas > 70%" atau "jual jika probabilitas < 30%". Sinyal-sinyal inilah yang akan menjadi pendorong utama transaksi otomatis atau manual dalam simulasi strategi.

Langkah terakhir adalah **Validasi dan Evaluasi**. Seluruh siklus dari pembuatan fitur hingga generasi sinyal harus divalidasi melalui simulasi historis. Proses ini, yang sering disebut *backtesting*, melibatkan simulasi perdagangan menggunakan sinyal yang dihasilkan oleh model pada data historis selama beberapa tahun. Penting untuk melakukan backtest dengan cara yang benar untuk menghindari optimisme berlebihan. Penggunaan teknik validasi silang urutan waktu, seperti Expanding Window Split, sangat direkomendasikan karena ia mensimulasikan cara pasar berkembang dari waktu ke waktu dan mencegah informasi dari masa depan "bocor" ke dalam model pelatihan [49]. Hasil backtest kemudian dievaluasi menggunakan metrik kinerja strategi perdagangan yang relevan, seperti total imbal hasil, rasio Sharpe, penarikan maksimum, dan profit factor [30, 48, 57]. Dengan demikian, mekanisme strategi yang diusulkan tidak hanya berfokus pada akurasi model, tetapi pada kemampuannya untuk menghasilkan keuntungan secara nyata, yang merupakan inti dari tujuan penelitian ini.

Analisis Komparatif Performa Model pada Aset XAU/USD (Emas)

Evaluasi komparatif antara XGBoost dan Random Forest untuk prediksi harga XAU/USD

(emas) menghadirkan gambaran yang kompleks dan seringkali saling bertentangan, yang menyoroti betapa bergantungnya performa model pada berbagai faktor seperti kerangka waktu, jenis metrik evaluasi, dan keseluruhan fitur yang digunakan. Tidak ada satu pun model yang secara universal superior; sebaliknya, keunggulan relatif keduanya tampak sangat kontekstual. Beberapa studi menunjukkan bahwa Random Forest unggul dalam tugas-tugas prediksi harga emas, sementara studi lain memberikan ruang bagi XGBoost untuk menunjukkan kekuatannya, terutama ketika data yang digunakan lebih heterogen.

Sebuah studi yang signifikan, yang dilakukan oleh Manoj Crasta (2024), secara langsung membandingkan Random Forest Regressor dan XGBoost untuk prediksi harga XAU/USD pada kerangka waktu per jam. Dataset yang digunakan mencakup sentimen berita (diukur dengan FinBERT), harga S&P 500, harga minyak mentah, dan indeks volatilitas VIX [2, 3]. Hasilnya menunjukkan bahwa Random Forest berhasil mengungguli XGBoost. Dalam kasus ini, Random Forest mencapai Mean Absolute Error (MAE) yang lebih rendah (7.2035) dan R-squared (R^2) yang sedikit lebih tinggi (0.9782) dibandingkan XGBoost yang mencatatkan MAE 8.5170 dan R^2 0.9760 [2]. Temuan ini menggarisbawahi keunggulan RF dalam menangani data campuran yang melibatkan indikator teknikal dan data fundamental/sentimen, mungkin karena sifatnya yang lebih robust terhadap fitur yang kurang relevan atau noise. Analisis fitur penting dari studi ini juga menunjukkan bahwa 'crude close' (harga tutup minyak mentah) dan 'sp_close' (harga tutup S&P 500) adalah prediktor yang paling signifikan, sementara 'sentiment score' memiliki pengaruh yang relatif lebih kecil, yang menunjukkan bahwa faktor fundamental ekuitas dan energi memiliki bobot yang lebih besar dalam menentukan harga emas dalam kerangka waktu tersebut [3].

Namun, gambaran tidak sepenuhnya mendukung RF. Sebuah studi oleh Zeynep Hilal Kilimci (2022) yang berfokus pada prediksi harian XAU/USD menemukan hasil yang berbeda. Dalam studi ini, model Stacking Regressor (yang merupakan model ensembler yang menggabungkan prediksi dari berbagai model termasuk XGBoost, Random Forest, dan lainnya) berhasil mencapai performa terbaik dengan Mean Absolute Percentage Error (MAPE) sebesar 2.2036 [2]. Ketika dianalisis secara terpisah, Random Forest mandiri mencatatkan MAPE yang lebih tinggi (4.2544) dibandingkan dengan model lain dalam kumpulan data tersebut, meskipun model XGBoost tidak diuji dalam studi ini [2]. Ini mengindikasikan bahwa dalam konteks prediksi harian dengan fitur yang lebih difokuskan pada indikator teknikal (Rata-Rata Bergerak, RSI, Band Bollinger), kombinasi model mungkin lebih unggul daripada model tunggal, dan keunggulan RF tidak selalu terjamin.

Selain itu, konteks kerangka waktu memainkan peran krusial. Studi oleh Yash Dave (2024) yang mengevaluasi berbagai model untuk pasangan forex termasuk XAU/USD menemukan bahwa XGBoost menunjukkan keunggulan pada kerangka waktu 4-jam, di mana ia mencapai RMSE (Root Mean Squared Error) terendah di antara semua model yang diuji (RMSE 0.0005) [3]. Sebaliknya, pada kerangka waktu yang lebih pendek (5-menit), model Random Forest justru menunjukkan profitabilitas tertinggi dalam simulasi perdagangan (9.2%), mengungguli model lainnya [3]. Wawasan ini sangat penting dan secara langsung relevan dengan tujuan penelitian ini. Ini mengimplikasikan bahwa implementasi kode pengguna kemungkinan besar memiliki parameter kerangka waktu yang berbeda untuk setiap model atau setiap

Secara umum, pemilihan parameter kerangka waktu yang berbeda untuk setiap model atau setiap aset, dan pemilihan model harus disesuaikan dengan frekuensi perdagangan yang diinginkan. XGBoost tampaknya lebih cocok untuk perdagangan spekulatif jangka menengah, sementara Random Forest mungkin lebih efektif untuk perdagangan frekuensi tinggi.

Model	Aset	Timeframe	Metrik Utama	Hasil	Sumber
Random Forest	XAU/USD	1 Jam	MAE, R ²	MAE: 7.2035, R ² : 0.9782	Crasta (2024) [2, 3]
XGBoost	XAU/USD	1 Jam	MAE, R ²	MAE: 8.5170, R ² : 0.9760	Crasta (2024) [2, 3]
Random Forest	XAU/USD	1 Hari	MAPE	4.2544	Kilimci (2022) [2]
XGBoost	XAU/USD	4 Jam	RMSE	Terendah (0.0005)	Dave (2024) [3]
Random Forest	XAU/USD	5 Menit	Profitabilitas Simulasi	9.2%	Behjoe (2025) [3]

Analisis fitur penting juga memberikan wawasan tentang apa yang sebenarnya dipelajari oleh model. Dalam studi Crasta (2024), fitur yang paling penting adalah 'crude close' dan 'sp_close', yang menekankan peran minyak dan pasar saham AS dalam menentukan harga emas [3]. Di sisi lain, studi oleh Alireza Behjoe (2025) pada XAU/USD pada kerangka waktu 5 menit hingga 4 jam menemukan bahwa indikator momentum dan pergerakan rata-rata seperti CCI_10, stoch_d_10, dan wma_20 adalah prediktor teratas [3]. Ini menunjukkan bahwa model dapat menangkap sinyal yang berbeda tergantung pada kerangka waktunya: pada kerangka waktu yang lebih rendah, sinyal momentum mungkin lebih dominan, sementara pada kerangka waktu yang lebih tinggi, sinyal fundamental mungkin lebih berpengaruh. Studi Abdelrahman Zewin (2026) menemukan temuan yang kontra-intuitif: penambahan data alternatif seperti Google Trends dan sentimen ternyata menyebabkan penurunan performa prediksi harga emas sekitar 2% untuk kedua model (XGBoost dan Quantile Regression Forest) [3]. Ini adalah peringatan penting bahwa tidak semua data ekstra otomatis meningkatkan kinerja model dan dapat menjadi sumber noise yang merugikan.

Secara keseluruhan, untuk XAU/USD, tidak ada model yang secara definitif lebih baik. Random Forest menunjukkan keunggulan dalam beberapa studi prediksi harga jangka pendek (1 jam) dan jangka panjang (5 menit), mungkin karena kekokohnya dan kemampuannya menangani data campuran [2, 3]. Namun, XGBoost menunjukkan performa superior dalam prediksi jangka menengah (4 jam) dan kemampuannya untuk mengintegrasikan berbagai jenis data [3]. Oleh karena itu, keberhasilan implementasi kode pengguna akan sangat bergantung pada fine-tuning parameter untuk setiap model pada kerangka waktu spesifik dan pemilihan fitur yang cerdas, menghindari data alternatif yang tidak relevan seperti yang disarankan oleh studi Zewin [3].

Analisis Komparatif Performa Model pada Aset BTC/USD (Bitcoin)

Perbandingan antara XGBoost dan Random Forest untuk prediksi harga BTC/USD (Bitcoin) menunjukkan pola yang berbeda dari yang diamati pada XAU/USD. Berbeda dengan emas yang sering kali berfungsi sebagai aset aman, Bitcoin adalah aset yang sangat reaktif terhadap sentimen pasar, kebijakan moneter, dan dinamika kripto-spesifik. Analisis terhadap literatur yang ada menunjukkan bahwa XGBoost sering kali menunjukkan keunggulan performa yang signifikan dalam konteks prediksi harga Bitcoin, baik dalam hal akurasi prediksi maupun profitabilitas strategi perdagangan.

Salah satu studi paling menonjol yang secara eksplisit membandingkan kedua model untuk Bitcoin adalah yang dilakukan oleh Corbet et al. (2020c). Dalam penelitian ini, XGBoost berhasil mencapai performa terkuat di antara berbagai model yang diuji. Secara spesifik, strategi berbasis XGBoost mampu menghasilkan imbal hasil kumulatif sebesar 141.4% dengan rasio Sharpe yang sangat impresif sebesar 1.78 [36]. Angka ini secara signifikan lebih tinggi dibandingkan dengan model lain, yang menunjukkan bahwa XGBoost tidak hanya mampu memprediksi arah harga dengan akurat tetapi juga menghasilkan keuntungan yang sangat baik setelah mempertimbangkan risiko. Studi lain yang menginvestigasi prediksi harga Bitcoin juga menemukan bahwa XGBoost mengungguli model seperti Long Short-Term Memory (LSTM) dalam hal paritas biaya [27]. Lebih jauh lagi, dalam analisis kinerja multi-model, XGBoost dan double deep Q-learning menunjukkan rasio Sharpe yang setara dan sangat kuat sebesar 0.63x, sementara model ARFIMA-GARCH (sebuah model ekonometrika tradisional) jauh di belakang karena imbal hasilnya yang lebih rendah [29].

Keunggulan XGBoost dalam konteks Bitcoin dapat diatribusikan pada beberapa faktor. Pertama, XGBoost sangat efektif dalam menangkap hubungan non-linear yang kompleks antara harga Bitcoin dan berbagai faktor prediktif. Kedua, kemampuannya untuk mengintegrasikan berbagai jenis data menjadi kekuatan utama. Studi oleh Yash Dave (2024) secara spesifik menyoroti bahwa XGBoost adalah model yang paling efektif dalam menggabungkan data teknikal, fundamental, dan data sentimen (misalnya, sentimen media sosial) untuk forecasting jangka pendek pada pasangan forex, termasuk XAU/USD [3]. Kemampuan untuk menangkap dampak dari berita positif atau negatif publik, yang sangat relevan untuk aset dengan basis penggemar yang kuat seperti Bitcoin, adalah keunggulan besar bagi XGBoost. Data on-chain, seperti volume transaksi dan jumlah alamat aktif, juga merupakan fitur penting yang dapat diintegrasikan oleh XGBoost untuk meningkatkan prediksinya [6, 47].

Di sisi lain, Random Forest juga telah diterapkan untuk prediksi harga Bitcoin, dan hasilnya bervariasi. Studi oleh Manoj Crasta (2024) menunjukkan bahwa Random Forest Regressor berhasil mengungguli XGBoost dalam prediksi harga XAU/USD per jam, namun studi tersebut tidak fokus pada Bitcoin [2]. Sebuah studi lain oleh Kim et al. (2020) menggunakan Random Forest sebagai salah satu model untuk memprediksi arah harga saham,

menunjukkan penerapan yang luas dari model ini di pasar keuangan [1]. Namun, dalam konteks Bitcoin secara spesifik, studi oleh Alireza Behjoe (2025) yang membandingkan berbagai model untuk XAU/USD pada kerangka waktu 5 menit hingga 4 jam tidak menyebutkan XGBoost sebagai model teratas untuk aset ini, melainkan menyoroti Random Forest dan LightGBM [3]. Ini menunjukkan bahwa keunggulan XGBoost mungkin lebih menonjol pada kerangka waktu tertentu atau dengan set fitur yang berbeda.

Model	Aset	Metrik Utama	Hasil	Sumber
XGBoost	BTC/USD	Imbal Hasil Kumulatif, Rasio Sharpe	141.4%, 1.78	Corbet et al. (2020c) [36]
XGBoost	BTC/USD	Rasio Sharpe	0.63x	Deep Learning for Financial Forecasting... [29]
Double Deep Q-Network	BTC/USD	Rasio Sharpe	0.63x	Deep Learning for Financial Forecasting... [29]
ARFIMA-GARCH	BTC/USD	Rasio Sharpe	Di bawah XGBoost	Deep Learning for Financial Forecasting... [29]
LSTM	BTC/USD	Paritas Biaya	Di bawah XGBoost	[27] [27]

Wawasan kritis yang dapat diekstraksi adalah bahwa keberhasilan strategi berbasis XGBoost untuk Bitcoin sangat bergantung pada kualitas dan relevansi fitur yang digunakan. Karena Bitcoin sangat reaktif terhadap kebijakan moneter bank sentral, terutama Federal Reserve AS, fitur yang merepresentasikan shock kebijakan moneter harus menjadi prioritas [16, 25]. Bitcoin juga menunjukkan karakteristik sebagai hedges terhadap inflasi ekspektasi dan kebijakan ekonomi AS, yang berarti model yang mampu menangkap respons ini akan memiliki keunggulan kompetitif [17, 18]. Studi oleh Corbet et al. (2020a) menunjukkan bahwa Bitcoin berfungsi sebagai tempat perlindungan selama krisis pandemi COVID-19, yang menggarisbawahi pentingnya fitur yang dapat menangkap sentimen "safe-haven" dalam pasar kripto [1].

Sebaliknya, Random Forest, meskipun mungkin tidak mencapai tingkat profitabilitas yang sama dengan XGBoost dalam beberapa studi, tetap merupakan model yang kuat dan layak dipertimbangkan. Keunggulannya dalam menangani fitur yang berbeda dan resistensi terhadap overfitting membuatnya menjadi model yang stabil dan dapat diandalkan [5]. Studi oleh Kim et al. (2020) menunjukkan bahwa Random Forest dapat digunakan untuk memprediksi arah harga saham, yang menunjukkan penerapan yang luas dari model ini di pasar keuangan [1]. Namun, dalam konteks Bitcoin yang sangat dinamis dan reaktif, kemampuan XGBoost untuk menangkap interaksi yang kompleks dan non-linear antara

kemampuan XGBoost untuk menangkap interaksi yang kompleks dan non-linear antara berbagai sumber data tampaknya memberikan keuntungan yang lebih signifikan. Oleh karena itu, berdasarkan bukti empiris yang ada, XGBoost tampaknya menjadi kandidat yang lebih menjanjikan untuk pengembangan strategi perdagangan yang menguntungkan pada aset BTC/USD dibandingkan dengan Random Forest.

Validasi Kontekstual: Dampak Volatilitas Pasar dan Tren Makroekonomi

Evaluasi kelayakan strategi perdagangan berbasis XGBoost dan Random Forest tidak akan lengkap tanpa memvalidasi kontekstualnya terhadap kondisi pasar global yang sedang berlangsung, terutama volatilitas dan tren makroekonomi. Efektivitas kedua algoritma ini sangat bergantung pada kemampuannya untuk menangkap dan merespons sinyal-sinyal fundamental ini, yang secara dinamis membentuk harga XAU/USD dan BTC/USD. Perilaku kedua aset ini, meskipun keduanya berada dalam kategori "logam", sangat berbeda dalam hal responsivitas terhadap faktor-faktor ekonomi makro.

Untuk XAU/USD (emas), posisinya sebagai aset safe-haven adalah kunci untuk memahami perilakunya. Emas sering kali menjadi pilihan investasi bagi para investor selama periode ketidakpastian ekonomi, inflasi yang tinggi, atau ketegangan geopolitik [1, 20]. Dalam lingkungan ini, permintaan untuk emas cenderung meningkat, mendorong harganya naik. Faktor-faktor makroekonomi yang paling berpengaruh adalah kebijakan moneter bank sentral, terutama The Federal Reserve. Kenaikan suku bunga oleh The Fed cenderung menekan harga emas karena meningkatkan daya tarik aset berbunga nol seperti emas, sementara pemotongan suku bunga sering kali mendorong harga emas naik [15]. Kajian literatur secara konsisten menunjukkan bahwa indikator seperti Indeks Volatilitas CBOE (VIX), yang mencerminkan kecemasan pasar, memiliki korelasi positif yang kuat dengan harga emas [2, 3]. Demikian pula, kinerja pasar saham, yang diwakili oleh indeks seperti S&P 500, juga berhubungan erat dengan harga emas, sering kali secara negatif [2]. Implementasi kode pengguna yang mengintegrasikan data ekonomi seperti S&P 500, harga minyak mentah, dan VIX sangat relevan dan didukung oleh bukti empiris [2, 3]. Keberhasilan model, terutama Random Forest dalam beberapa studi, mungkin disebabkan oleh kemampuannya untuk secara efektif menangkap hubungan linear dan non-linear ini [3].

Kondisi pasar emas pada tahun 2025 dan 2026 tampaknya mendukung relevansi strategi ini. Seperti yang dilaporkan, harga emas mencapai rekor baru di \$3,703 per ons pada bulan September 2025, menunjukkan permintaan yang kuat meskipun ada perkiraan bahwa The Fed akan menahan kenaikan suku bunga pada kuartal pertama 2026 [15, 20]. Dalam konteks pasar yang penuh volatilitas, model machine learning yang dapat menangkap sinyal-sinyal fundamental ini menjadi sangat berharga. Namun, terdapat kesenjangan potensial. Sebuah studi oleh Abdelrahman Zewin (2026) menemukan bahwa penambahan data alternatif seperti sentimen berita dan VIX justru menyebabkan penurunan performa prediksi harga emas sekitar 2% [3]. Temuan ini menyerukan peringatan penting: tidak semua data fundamental otomatis bermanfaat. Penelitian ini harus secara empiris memverifikasi apakah

titur-titir tambahan yang diimplementasikan pengguna benar-benar meningkatkan atau malah merugikan kinerja model.

Untuk BTC/USD (Bitcoin), konteks makroekonominya berbeda namun sama-sama kritis. Bitcoin dikenal sangat reaktif terhadap kebijakan moneter The Fed [16, 25]. Bitcoin menunjukkan reaksi harga yang signifikan terhadap kejutan kebijakan moneter, dengan adanya harga drift yang signifikan dalam beberapa hari setelah pertemuan FOMC [16]. Oleh karena itu, fitur yang merepresentasikan kebijakan moneter AS harus menjadi fitur prioritas dalam model prediksi Bitcoin. Bitcoin juga semakin dianggap sebagai aset alternatif atau "digital gold", yang berfungsi sebagai lindung nilai terhadap ketidakpastian ekonomi dan kebijakan pemerintah [17, 20]. Beberapa studi bahkan menemukan bahwa Bitcoin berfungsi sebagai lindung nilai terhadap ekspektasi inflasi [18]. Namun, hubungannya dengan emas masih menjadi subjek perdebatan, dengan beberapa penelitian menemukan hubungan yang tidak linier dan asimetris, terutama selama periode gejolak [1]. Ini berarti bahwa model prediksi untuk Bitcoin tidak boleh mengabaikan dinamika pasar tradisional seperti emas, terutama selama krisis.

Sentimen publik juga memainkan peran ganda untuk Bitcoin. Di satu sisi, sentimen positif dari media sosial dan berita dapat mendorong harga naik [28]. Di sisi lain, sentimen negatif atau berita yang meragukan dapat menyebabkan penurunan harga yang drastis. Data on-chain, seperti volume transaksi dan jumlah alamat aktif, juga memberikan wawasan yang berharga tentang aktivitas pengguna dan nilai intrinsik Bitcoin [6, 47]. Keberhasilan XGBoost dalam prediksi harga Bitcoin kemungkinan besar disebabkan oleh kemampuannya yang superior dalam mengintegrasikan semua jenis data ini—makroekonomi, sentimen, dan on-chain—dan menangkap interaksi kompleks di antara mereka [3, 36].

Dari perspektif volatilitas, pasar kripto secara inheren lebih volatil daripada pasar logam tradisional. Gejolak connectedness di antara kripto besar seperti Bitcoin, Ethereum, dan Ripple telah menjadi subjek penelitian yang intensif [1]. Strategi perdagangan yang dikembangkan harus mampu mengelola risiko yang lebih tinggi ini. Metrik seperti Maximum Drawdown (MDD) menjadi sangat penting untuk dievaluasi. Sebuah studi menunjukkan bahwa strategi dengan Profit Factor rendah (0.44) dan rasio Sharpe negatif menunjukkan kinerja yang lemah, yang sering kali disebabkan oleh MDD yang tinggi (-7.06%) [7]. Oleh karena itu, validasi kontekstual tidak hanya tentang apakah model dapat memprediksi arah harga, tetapi juga tentang bagaimana strategi perdagangan yang dihasilkannya dapat menavigasi volatilitas pasar kripto yang ekstrem. Dengan demikian, perbandingan antara XGBoost dan Random Forest harus dilakukan dengan mempertimbangkan kemampuan masing-masing model untuk menangkap sinyal-sinyal makroekonomi yang berbeda ini dan mengevaluasi kinerja strategi mereka dalam mengelola risiko yang melekat pada setiap aset.

Kerangka Evaluasi, Metrik Kinerja, dan Analisis Risiko Strategis

Penilaian kelayakan strategi perdagangan berbasis XGBoost dan Random Forest memerlukan kerangka evaluasi yang komprehensif, mencakup dua level metrik yang berbeda: metrik untuk mengevaluasi kinerja model machine learning itu sendiri, dan metrik

yang lebih substansial untuk mengevaluasi profitabilitas dan risiko dari strategi perdagangan yang dihasilkannya. Selain itu, analisis risiko strategis yang kritis sangat penting untuk memahami potensi kegagalan dan batasan dari pendekatan yang diusulkan.

Pada level model machine learning, metrik standar digunakan untuk menilai akurasi dan presisi prediksi. Untuk tugas regresi (memprediksi harga mutlak), metrik yang umum digunakan adalah Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan R-squared (R^2) [2, 57]. MAE memberikan rata-rata besaran kesalahan prediksi, menjadikannya mudah diinterpretasikan. RMSE memberikan bobot yang lebih besar pada kesalahan yang lebih besar, menjadikannya lebih sensitif terhadap outlier. R^2 mengukur seberapa besar variasi dalam variabel target yang dapat dijelaskan oleh model. Untuk tugas klasifikasi (memprediksi arah pergerakan harga), metrik yang relevan termasuk Akurasi, Presisi, Recall, dan Skor F1 [57]. Akurasi memberikan persentase prediksi yang benar, sementara Presisi (proporsi prediksi positif yang benar) dan Recall (proporsi aktual positif yang terdeteksi dengan benar) memberikan pandangan yang lebih dalam tentang kinerja model dalam konteks perdagangan, di mana biaya dari kesalahan jenis tertentu bisa sangat berbeda.

Namun, metrik-metrik ini saja tidak cukup untuk menentukan kelayakan strategi perdagangan. Kinerja model harus dinaikkan levelnya ke metrik kinerja portofolio. Ini adalah inti dari evaluasi strategi. Metrik-metrik ini mencakup:

- 1. **Total Return / Annualized Return:** Mengukur total keuntungan atau kerugian yang dihasilkan oleh strategi perdagangan, biasanya disajikan sebagai imbal hasil kumulatif atau tahunan [48, 52].
- 2. **Sharpe Ratio:** Salah satu metrik risiko-adjusted return yang paling populer. Rasio ini mengukur imbal hasil harian dari strategi per unit volatilitas (deviasi standar) [12]. Rasio Sharpe yang lebih tinggi menunjukkan kinerja yang lebih baik untuk setiap unit risiko yang diambil. Studi-studi sering kali menyoroti rasio Sharpe sebagai tolok ukur keunggulan strategi [29, 30, 36].
- 3. **Maximum Drawdown (MDD):** Mengukur kerugian maksimum dari puncak ke lembah dalam portofolio selama periode tertentu. Ini adalah metrik risiko yang sangat penting karena menggambarkan potensi kerugian terburuk yang mungkin dialami seorang trader, yang sangat relevan dalam pasar yang sangat volatil seperti kripto [7, 30].
- 4. **Profit Factor:** Dirumuskan sebagai total keuntungan bruto dibagi dengan total kerugian bruto. Nilai di atas 1 menunjukkan bahwa strategi menghasilkan keuntungan. Nilai yang lebih tinggi menunjukkan efisiensi strategi dalam menghasilkan keuntungan dibandingkan dengan kerugiannya [7, 57].
- 5. **Win Rate:** Persentase perdagangan yang menghasilkan keuntungan. Meskipun penting, win rate tunggal tidak memberikan gambaran lengkap tanpa mempertimbangkan ukuran keuntungan dan kerugian [42, 52].

Berikut adalah tabel ringkasan metrik evaluasi yang akan digunakan:

Level	Metrik	Deskripsi Singkat	Relevansi untuk Strategi
-------	--------	-------------------	--------------------------

Evaluasi	Metrik	Contoh Penggunaan	Relevansi dalam Strategi
Model ML	MAE, RMSE, R^2	Mengukur akurasi prediksi numerik model.	Dasar untuk memahami kemampuan model dalam memprediksi harga.
Model ML	Accuracy, F1-Score	Mengukur akurasi prediksi klasifikasi model.	Penting untuk strategi yang berbasis sinyal biner ('naik'/'turun').
Strategi Trading	Total Return, Annualized Return	Mengukur keuntungan finansial total dari strategi.	Tujuan utama dari setiap strategi perdagangan.
Strategi Trading	Sharpe Ratio	Mengukur imbal hasil per unit risiko/volatilitas.	Memungkinkan perbandingan strategi dengan tingkat risiko yang berbeda.
Strategi Trading	Maximum Drawdown (MDD)	Mengukur kerugian maksimum yang dialami.	Menilai kerentanan strategi terhadap periode kinerja buruk.
Strategi Trading	Profit Factor	Membandingkan total keuntungan vs. total kerugian.	Mengukur efisiensi dan profitabilitas bersih strategi.
Strategi Trading	Win Rate	Persentase perdagangan yang berhasil.	Memberikan gambaran tentang frekuensi keberhasilan sinyal.

Analisis risiko strategis adalah komponen krusial dari penilaian kelayakan. Ada beberapa alasan mengapa ide ini bisa gagal. Pertama, **Overfitting**: Model machine learning, terutama XGBoost yang kompleks, sangat rentan terhadap overfitting, di mana model belajar pola-pola acak dalam data latih tetapi gagal berkinerja di pasar dunia nyata. Tanpa validasi silang urutan waktu yang ketat, hasil backtest yang bagus bisa menjadi ilusi [49]. Kedua, **Perubahan Dinamika Pasar**: Pasar keuangan tidak statis. Pola yang berhasil pada data historis mungkin tidak lagi berlaku di masa depan karena perubahan regulasi, perilaku investor, atau faktor makroekonomi baru. Ketiga, **Biaya Transaksi dan Slippage**: Strategi yang sering bertransaksi (seperti yang mungkin dihasilkan oleh model frekuensi tinggi) bisa jadi menjadi tidak menguntungkan setelah memperhitungkan biaya transaksi dan selip harga. Keempat, **Temuan Kontra-intuitif**: Seperti yang ditunjukkan oleh studi Zewin (2026), penambahan fitur yang tampaknya relevan (seperti sentimen berita) justru dapat menurunkan performa model [3]. Mengasumsikan semua fitur yang digunakan bermanfaat bisa menjadi kesalahan fatal.

Sebaliknya, ada juga argumen mengapa ide ini bisa menguntungkan. Keuntungannya terletak pada kemampuan model machine learning untuk menangkap hubungan non-linear yang sangat kompleks yang mungkin luput dari analisis manusia atau model statistik.

yang sangat kompleks yang mungkin luput dari analisis manusia atau model statistik tradisional [54]. XGBoost, khususnya, menunjukkan potensi luar biasa dalam mengintegrasikan berbagai jenis data (teknikal, fundamental, sentimen) dan telah terbukti menghasilkan rasio Sharpe yang sangat tinggi untuk aset kripto seperti Bitcoin [29, 36]. Random Forest, sementara mungkin tidak selalu menjadi yang terbaik dalam hal akurasi prediksi tertinggi, menawarkan kekokohan dan stabilitas yang membuatnya menjadi model yang andal, terutama untuk aset seperti emas yang responsif terhadap berbagai sinyal fundamental [2, 3]. Dengan demikian, kesimpulannya bukan pada klaim absolut, tetapi pada identifikasi konteks di mana masing-masing model dapat memberikan keunggulan. Keberhasilan penelitian ini bergantung pada implementasi metodologi yang ketat, pemilihan fitur yang cerdas, dan interpretasi hasil yang bijaksana, dengan mengakui bahwa tidak ada satu pun model yang secara universal superior.